

人工智能综合实训 II

实 训 报 告

题 目： 机器学习与手写 AlexNet 图像分类

学 院： 人工智能与低空技术学院

专 业： 人工智能

小组成员： 雷正 蔡铭飞 冼嘉谦

指导教师： 赵静

2026 年 5 月 30 日

摘 要

随着人工智能技术的迅速发展，机器学习已成为数据分析与智能决策的核心工具。本实训围绕“机器学习全流程实践”展开，完成两个相互独立又层层递进的项目，系统覆盖结构化数据建模与图像深度学习两大方向。**项目一**面向结构化数据，在 UCI 白葡萄酒质量数据集上构建多分类模型，系统对比了支持向量机、决策树、随机森林与逻辑回归四种算法，采用网格搜索与五折交叉验证进行超参数寻优，并使用准确率、精确率、召回率、宏平均 F1 等指标进行评估。实验结果表明，集成学习方法随机森林取得最佳性能，测试集准确率 73.5%、宏平均 F1 为 0.734，显著优于线性模型。**项目二**面向图像数据，依据经典论文逐层手工实现卷积神经网络 AlexNet（不调用任何预置模型），在 Fashion-MNIST 数据集上完成十分类任务。模型经 15 轮训练后在测试集上达到 91.55% 的准确率、宏平均 F1 为 0.915。两个项目完整覆盖了数据加载、可视化、预处理、模型建立、模型评估与结论分析的全流程，验证了集成学习在结构化数据上的优势以及深度卷积网络在图像识别上的有效性，并在实践中积累了数据处理、模型调优与工程实现的经验，最后提出了若干改进方向。

关键词：机器学习；支持向量机；随机森林；卷积神经网络；AlexNet；图像分类

目录

1	引言	3
1.1	研究背景与意义	3
1.2	国内外研究现状	3
1.3	项目研究思路	3
1.4	小组成员分工	4
2	相关理论基础	5
2.1	监督学习与分类问题	5
2.2	传统机器学习算法	5
2.2.1	支持向量机 (SVM)	5
2.2.2	决策树	5
2.2.3	随机森林	6
2.2.4	逻辑回归	6
2.3	卷积神经网络与 AlexNet	6
2.4	模型评估指标	7
3	项目一：红酒质量分类	7
3.1	数据集介绍与来源	7
3.2	数据加载与可视化分布	7
3.3	数据预处理	9
3.4	模型建立	9
3.5	模型评估	9
3.6	本章小结	11
4	项目二：手写 AlexNet 图像分类	12
4.1	数据集介绍与来源	12
4.2	数据加载与可视化	12
4.3	数据预处理	12
4.4	模型建立	12
4.5	模型评估	13
4.6	本章小结	16
5	结论与实验总结	16
5.1	结论	16
5.2	实验总结	16
5.3	改进方案	16

1 引言

1.1 研究背景与意义

人工智能是研究、开发用于模拟和扩展人类智能的理论、方法与技术的科学，而机器学习作为其最重要的分支，致力于让计算机系统通过经验（数据）自动改善性能，而无需被显式编程。近年来，得益于数据规模的爆炸式增长与计算硬件（尤其是 GPU）的进步，机器学习在图像识别、自然语言处理、推荐系统、医疗诊断等众多领域取得了突破性进展，深刻改变了人们的生产与生活方式。

按照数据形态的不同，机器学习任务大致可分为两类：一类是面向结构化（表格）数据的任务，典型如分类与回归，通常采用支持向量机、决策树、集成学习等传统算法；另一类是面向图像、语音、文本等非结构化数据的任务，主要依赖深度神经网络。本实训分别选取这两类任务的代表性问题——红酒质量分级与服饰图像分类，通过完整的工程实践，加深对机器学习核心思想、典型算法与建模流程的理解，培养从数据到模型、再到结论的综合实践能力，具有重要的学习与应用价值。

1.2 国内外研究现状

在传统机器学习方面，支持向量机由 Vapnik 等人于 20 世纪 90 年代提出，凭借坚实的统计学习理论基础和优秀的小样本泛化能力，长期是分类任务的重要工具；以随机森林、梯度提升树（GBDT、XGBoost、LightGBM）为代表的集成学习方法，通过组合多个弱学习器进一步提升了精度与鲁棒性，至今仍是结构化数据竞赛中的主流方案。在深度学习方面，2012 年 Krizhevsky 等人提出的 AlexNet 在 ImageNet 竞赛中以显著优势夺冠，掀起了深度卷积网络的研究热潮；此后 VGG、GoogLeNet、ResNet 等更深、更高效的网络结构相继涌现，不断刷新图像识别的精度上限。本实训以经典且最具代表性的 AlexNet 为研究对象，逐层复现其结构，旨在透彻理解卷积神经网络的工作机制。

1.3 项目研究思路

本实训采用统一的机器学习方法论，对两个项目均遵循如下六个环节循序推进，整体流程如图 1 所示：

- （1）**数据加载**：从公开数据源获取数据集，读入内存并核对规模、字段与完整性；
- （2）**数据查看**：通过描述性统计与可视化了解数据分布、相关性与潜在问题；
- （3）**数据预处理**：包括标签构造、特征标准化、数据集划分以及类别不平衡处理；
- （4）**模型建立**：根据任务特点选择合适的算法或网络结构，并通过调参确定最优配置；

- (5) **模型评估**：在独立测试集上用多种指标量化性能，并借助混淆矩阵等工具深入分析；
- (6) **结论分析**：归纳实验结果，对比模型优劣，总结经验并提出改进方案。




图 1: 机器学习项目统一研究流程

1.4 小组成员分工

本项目由小组协作完成，成员分工如表 1 所示。

表 1: 小组成员分工表

学号	姓名	主要分工
202434610309	雷正	项目一数据预处理与机器学习建模、调参与评估
202434610301	蔡铭飞	项目二 AlexNet 网络实现、模型训练与可视化评估
202434610326	冼嘉谦	数据可视化、报告撰写、PPT 制作与汇报

2 相关理论基础

2.1 监督学习与分类问题

监督学习是机器学习中最常见的范式,其任务是在给定带标签的训练集 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ 上学习一个映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$, 使其对未知样本具有良好的预测能力。当标签 y 取离散值时即为**分类问题**。本实训两个项目均属于多分类问题: 项目一为三分类(红酒质量等级), 项目二为十分类(服饰类别)。模型学习的核心是最小化训练数据上的损失函数, 同时通过正则化、交叉验证等手段控制模型复杂度以提升泛化能力。

2.2 传统机器学习算法

2.2.1 支持向量机 (SVM)

支持向量机的基本思想是在特征空间中寻找一个最大间隔超平面以分隔不同类别。其优化目标为:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i, \quad \text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0, \quad (1)$$

其中 C 为惩罚系数, ξ_i 为松弛变量。对于非线性可分问题, SVM 通过核函数将样本映射到高维空间, 本实训采用径向基 (RBF) 核: $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$ 。

2.2.2 决策树

决策树通过递归地选择最优特征对样本空间进行划分, 形成树状的判别结构。划分依据通常为基尼不纯度:

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2, \quad (2)$$

其中 p_k 为类别 k 在节点中的占比。算法每次选择使子节点不纯度下降最大的特征进行分裂，具有良好的可解释性，但单棵树容易过拟合。

2.2.3 随机森林

随机森林是一种基于 Bagging 思想的集成学习方法，通过自助采样 (Bootstrap) 构建多棵决策树，并在每次分裂时随机选取部分特征，最后对所有树的预测结果进行多数表决：

$$\hat{y} = \text{mode}\{T_1(\mathbf{x}), T_2(\mathbf{x}), \dots, T_M(\mathbf{x})\}. \quad (3)$$

随机性的引入降低了模型方差，使其在保持高精度的同时具有较强的抗过拟合能力。

2.2.4 逻辑回归

逻辑回归是一种线性分类模型，通过 Softmax (多分类) 函数将线性输出映射为类别概率：

$$P(y = k | \mathbf{x}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x})}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x})}, \quad (4)$$

并以交叉熵为损失函数进行参数估计。其结构简单、训练高效，常作为分类任务的基线模型。

2.3 卷积神经网络与 AlexNet

卷积神经网络 (CNN) 是处理图像数据的主流深度模型，其核心组件包括：

- **卷积层**：通过可学习的卷积核在图像上滑动提取局部特征，具有局部连接与权重共享的特点，大幅减少参数量。给定输入尺寸 W 、卷积核 K 、步长 S 、填充 P ，输出尺寸为 $O = \lfloor (W - K + 2P)/S \rfloor + 1$ 。
- **激活函数 ReLU**： $f(x) = \max(0, x)$ ，引入非线性并缓解梯度消失，是 AlexNet 的关键创新之一。
- **池化层**：通过最大池化等操作进行下采样，降低特征图尺寸、增强平移不变性。
- **局部响应归一化 (LRN)**：对相邻通道的响应进行归一化，增强模型的泛化能力。
- **Dropout**：训练时以一定概率随机置零神经元输出，有效抑制过拟合。
- **全连接层**：将提取到的高层特征映射到类别空间，输出分类结果。

AlexNet 由 5 个卷积层与 3 个全连接层堆叠而成，首次将 ReLU、Dropout、数据增强与 GPU 训练有机结合，是深度学习发展史上的里程碑。

2.4 模型评估指标

对于分类任务，依据混淆矩阵中的真正例 TP、假正例 FP、真负例 TN、假负例 FN，常用指标定义如下：

$$\text{准确率} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{精确率} = \frac{TP}{TP + FP}, \quad \text{召回率} = \frac{TP}{TP + FN}, \quad (5)$$

$$F1 = \frac{2 \cdot \text{精确率} \cdot \text{召回率}}{\text{精确率} + \text{召回率}}. \quad (6)$$

对于多分类问题，常计算各类别指标的算术平均，即**宏平均** (Macro-average)，它对每个类别一视同仁，能更好地反映模型在不平衡数据上的综合表现。混淆矩阵则以矩阵形式展示各类别的预测分布，可直观分析模型的混淆情况。

3 项目一：红酒质量分类

3.1 数据集介绍与来源

本项目采用 **UCI 机器学习仓库**公开的葡萄酒质量数据集 (Wine Quality Data Set)，来源网址为 <https://archive.ics.uci.edu/dataset/186/wine+quality>。其中白葡萄酒子集共 **4898** 个样本，每个样本包含 **11** 个理化特征以及 1 个质量评分标签 (0–10 的整数，由品酒师综合评定)。各特征的含义如表 2 所示。

表 2: 白葡萄酒数据集特征说明

特征	含义	特征	含义
fixed acidity	固定酸度 (酒石酸)	total sulfur dioxide	总二氧化硫
volatile acidity	挥发性酸度 (醋酸)	density	密度
citric acid	柠檬酸	pH	酸碱度
residual sugar	残糖	sulphates	硫酸盐
chlorides	氯化物	alcohol	酒精度
free sulfur dioxide	游离二氧化硫	quality	质量评分 (标签)

3.2 数据加载与可视化分布

数据以分号分隔的 CSV 文件存储，使用 `pandas` 读入后核验为 4898×12 (11 特征 + 1 标签)，经检查无缺失值与重复值，数据质量良好。为深入理解数据特性，绘制了质量评分的分布直方图 (图 2) 与特征相关性热力图 (图 3)。




图 2: 葡萄酒质量评分分布

由分布图可见，质量评分高度集中于 5、6、7 三档，评分为 6 的样本最多，而极高（8、9）与极低（3、4）评分的样本极少，整体呈现明显的“中间多、两端少”的长尾不平衡特征，这给少数类的识别带来了挑战。由相关性热力图（图 3）可见，酒精度（alcohol）与质量评分呈较强的正相关，而密度（density）与质量评分呈负相关，二者本身又高度负相关；这与酿酒学常识一致——酒精度越高往往口感越佳，表明所选特征对质量判别具备一定的有效信息。




图 3: 特征相关性热力图

3.3 数据预处理

针对原始数据与任务特点，进行如下预处理：

- (1) **标签构造**：原始质量评分有 7 个取值且极不均衡，直接做七分类意义有限。故将其分箱为三个等级——评分 ≤ 5 记为“差”（类 0）、 $= 6$ 记为“中”（类 1）、 ≥ 7 记为“好”（类 2）。分箱后三类样本数分别为 1640、2198、1060，更符合实际的质量分级需求。
- (2) **特征标准化**：由于各特征量纲差异较大（如 total sulfur dioxide 可达上百，而 density 接近 1），采用 $z = (x - \mu)/\sigma$ 对 11 个特征进行零均值、单位方差标准化。标准化参数仅在训练集上拟合后再应用到测试集，以严格避免数据泄漏。
- (3) **数据集划分**：按 8:2 进行分层抽样划分，得到训练集 3918 个、测试集 980 个样本，分层抽样保证训练集与测试集中各类别比例与总体一致。
- (4) **不平衡处理**：考虑到类别不平衡，所有模型统一设置 `class_weight='balanced'`，按类别频率的反比为样本加权，使模型更关注少数类，避免被多数类主导。

3.4 模型建立

选取支持向量机、决策树、随机森林、逻辑回归四种代表性算法（原理见 2.2 节），通过五折交叉验证结合网格搜索（评分准则为宏平均 F1）对关键超参数进行寻优，各模型的搜索空间与最优结果见表 3。五折交叉验证将训练集均分为五份，轮流以其中四份训练、一份验证，取平均性能作为该超参数组合的评分，从而更稳健地选择超参数、降低过拟合风险。

表 3: 四种模型的搜索空间与最优超参数

模型	主要搜索空间	最优超参数
SVM	$C \in \{1, 10\}$, $\gamma \in \{\text{scale}, 0.1\}$, RBF 核	$C = 10$, $\gamma = 0.1$
决策树	最大深度 $\in \{\text{None}, 10, 20\}$, 叶子最小样本 $\in \{1, 5\}$	深度 None, 叶子 1
随机森林	树数 $\in \{200, 400\}$, 最大深度 $\in \{\text{None}, 20\}$	树数 200, 深度 20
逻辑回归	$C \in \{0.5, 1, 10\}$	$C = 0.5$

3.5 模型评估

在独立测试集上对四个模型进行评估，整体指标对比见表 4 与图 4。

表 4: 四种机器学习模型测试集性能对比

模型	准确率	精确率	召回率	宏平均 F1
SVM	0.617	0.616	0.660	0.622
决策树	0.650	0.647	0.644	0.645
随机森林	0.735	0.748	0.723	0.734
逻辑回归	0.522	0.524	0.567	0.520




图 4: 各模型测试集指标对比

由表 4 可见，随机森林在四项指标上全面领先，其次为决策树与 SVM，逻辑回归表现最差。为进一步分析最优模型，给出随机森林各类别的详细指标（表 5）及其混淆矩阵（图 5）。

表 5: 随机森林各类别精确率/召回率/F1

类别	精确率	召回率	F1	样本数
差 (≤ 5)	0.78	0.73	0.76	328
中 ($= 6$)	0.69	0.77	0.73	440
好 (≥ 7)	0.77	0.67	0.72	212

从各类别指标看，随机森林对“差”“好”两端类别的精确率较高，而“中”类样本最多、与相邻等级边界模糊，召回率虽高但精确率相对偏低，这与质量评分本身的

连续性、相邻等级难以截然区分的特点相符。




图 5: 随机森林混淆矩阵

此外，随机森林可输出特征重要性（图 6），结果显示酒精度、密度与挥发性酸度对质量判别贡献最大，与相关性分析的结论相互印证。




图 6: 随机森林特征重要性排序

3.6 本章小结

实验表明，随机森林在所有指标上均显著领先，宏平均 F1 达 0.734，比次优的决策树高出约 9 个百分点；逻辑回归作为线性模型表现最差（F1 仅 0.520），说明该任务中特征与质量之间存在较强的非线性关系，线性模型难以刻画，而集成学习能更好地

拟合复杂的决策边界，并通过多树投票降低方差、提升鲁棒性。特征重要性进一步揭示了影响葡萄酒质量的关键理化指标，体现了机器学习模型在数据分析中的可解释价值。

4 项目二：手写 AlexNet 图像分类

4.1 数据集介绍与来源

本项目采用 **Fashion-MNIST** 数据集，由德国 Zalando 公司发布，来源网址为 <https://www.kaggle.com/datasets/zalando-research/fashionmnist> (亦可经 torchvision 自动下载)。数据集共 **70000** 张 28×28 的灰度服饰图像，其中训练集 60000 张、测试集 10000 张，均匀覆盖 10 个类别：T 恤、裤子、套衫、连衣裙、外套、凉鞋、衬衫、运动鞋、包、短靴。相比经典的手写数字 MNIST，Fashion-MNIST 类间相似度更高、纹理更复杂、识别难度更大，已成为评估图像分类算法的标准基准数据集之一。

4.2 数据加载与可视化

通过 `torchvision.datasets.FashionMNIST` 接口自动下载并加载数据。由于 AlexNet 的标准输入为 224×224 ，在加载时通过 `Resize` 将原始 28×28 图像放大至 224×224 。部分测试样例及其预测结果如图 9 所示（绿色标题表示预测正确，红色表示预测错误），可见模型对大多数样本判别准确，仅在视觉相似的上装类别间偶有混淆。

4.3 数据预处理

图像预处理流程包括：(1) `Resize(224)` 将图像缩放到网络所需尺寸；(2) `ToTensor` 将像素值转为张量并归一化到 $[0, 1]$ ；(3) `Normalize` 按 Fashion-MNIST 的单通道均值 0.2860、标准差 0.3530 进行标准化，使输入分布更利于网络收敛。此外，从 60000 张训练图中随机划出 10% 作为验证集用于训练过程中的模型选择（保存验证集表现最优的模型），最终在独立的 10000 张测试图上评估。

4.4 模型建立

按照经典 AlexNet 论文，使用 `nn.Conv2d`、`nn.MaxPool2d`、`nn.Linear` 等基础算子逐层手工搭建网络，不调用 `torchvision.models` 中的任何预置 AlexNet。网络输入为 $1 \times 224 \times 224$ 的灰度图，由 5 个卷积块与 3 个全连接层构成，各层配置与输出尺寸见表 6，总参数量约 58.3M。其中卷积层负责逐级提取由边缘、纹理到语义部件的层次化特征，池化层逐步降低空间分辨率，全连接层完成最终的类别判别。

表 6: 手写 AlexNet 网络结构

层	配置	输出尺寸
输入	灰度图像	$1 \times 224 \times 224$
Conv1	96 核, 11×11 , 步长 4, 填充 2; ReLU+LRN	$96 \times 55 \times 55$
MaxPool1	3×3 , 步长 2	$96 \times 27 \times 27$
Conv2	256 核, 5×5 , 填充 2; ReLU+LRN	$256 \times 27 \times 27$
MaxPool2	3×3 , 步长 2	$256 \times 13 \times 13$
Conv3	384 核, 3×3 , 填充 1; ReLU	$384 \times 13 \times 13$
Conv4	384 核, 3×3 , 填充 1; ReLU	$384 \times 13 \times 13$
Conv5	256 核, 3×3 , 填充 1; ReLU	$256 \times 13 \times 13$
MaxPool3	3×3 , 步长 2	$256 \times 6 \times 6$
全连接 FC6	Dropout(0.5) + Linear; ReLU	4096
全连接 FC7	Dropout(0.5) + Linear; ReLU	4096
全连接 FC8	Linear (输出层)	10

训练配置：损失函数采用交叉熵 $L = -\sum_i y_i \log \hat{y}_i$ ；优化器为带动量的随机梯度下降 (SGD, 动量 0.9, 权重衰减 5×10^{-4})，其更新规则为 $v \leftarrow \beta v - \eta \nabla L$, $\theta \leftarrow \theta + v$ ，动量项有助于加速收敛并抑制震荡；初始学习率 0.01，采用步长为 10、衰减系数 0.1 的学习率调度 (StepLR)，即每 10 轮将学习率降为原来的 1/10 以便后期精细收敛；批大小 128，共训练 15 轮，按验证集准确率保存最优模型。训练在单张 NVIDIA RTX 4090 GPU 上完成，约耗时十余分钟。

4.5 模型评估

训练与验证过程的损失、准确率曲线见图 7。可见训练初期损失迅速下降、准确率快速提升，随后平稳收敛；验证集最高准确率为 0.9232，且在第 10 轮学习率衰减后性能出现一次小幅跃升，训练曲线与验证曲线基本贴合，未见明显过拟合，表明 Dropout 与权重衰减起到了有效的正则化作用。




图 7: AlexNet 训练/验证损失与准确率曲线

在 10000 张测试图像上，模型最终准确率为 **91.55%**，宏平均精确率、召回率、F1 均为 0.915。各类别详细指标见表 7，整体混淆情况见图 8。

表 7: AlexNet 各类别测试指标

类别	精确率	召回率	F1	类别	精确率	召回率	F1
T 恤	0.87	0.85	0.86	凉鞋	0.98	0.98	0.98
裤子	0.99	0.98	0.99	衬衫	0.76	0.74	0.75
套衫	0.87	0.87	0.87	运动鞋	0.96	0.97	0.96
连衣裙	0.91	0.94	0.92	包	0.98	0.98	0.98
外套	0.84	0.89	0.86	短靴	0.97	0.96	0.97




图 8: AlexNet 测试集混淆矩阵




图 9: 测试集预测样例（绿色为正确，红色为错误）

4.6 本章小结

手写 AlexNet 在 Fashion-MNIST 上取得了 91.55% 的测试准确率，验证了所实现网络的正确性与有效性。从混淆矩阵与各类指标看，“裤子”“包”“凉鞋”“短靴”等形态独特的类别识别率接近完美 ($F1 \geq 0.97$)，而“衬衫”类最易混淆 ($F1$ 仅 0.75)，主要与“T 恤”“套衫”“外套”相互误判——这些上装在低分辨率灰度图下轮廓与纹理高度相似，是 Fashion-MNIST 公认的识别难点。这也说明，进一步提升性能需要更强的特征提取能力或更精细的数据增强策略。

5 结论与实验总结

5.1 结论

本实训完整实现了两类典型的机器学习任务并得出如下结论：

- (1) 在结构化数据的红酒质量分类中，集成学习方法（随机森林）显著优于单一模型与线性模型，测试集宏平均 $F1$ 达 0.734，是四种算法中的最佳选择；这印证了集成学习在中小规模结构化数据上的普遍优势。
- (2) 在图像分类任务中，逐层手写实现的 AlexNet 能够有效学习服饰图像的层次化特征，测试准确率达 91.55%，充分验证了深度卷积网络在视觉任务上的强大能力以及本次复现的正确性。

5.2 实验总结

通过本次实训，我们完整走通了“数据加载—查看—预处理—建模—评估—结论”的机器学习全流程，并获得如下收获：其一，深入理解了传统机器学习与深度学习在数据形态、建模思路与适用场景上的差异；其二，掌握了标准化、分层划分、类别加权等预处理手段及其对结果的影响，体会到“数据决定模型上限”的重要性；其三，熟悉了网格搜索与交叉验证在超参数调优中的作用；其四，通过亲手逐层实现 AlexNet，透彻理解了卷积、池化、ReLU、LRN、Dropout 等核心组件的原理与协同机制。在工程实践中，我们还解决了诸如绘图中文字体缺失数字字形、scikit-learn 新版本参数变更等实际问题，锻炼了独立排查与解决问题的能力。

5.3 改进方案

针对两个项目，后续可从以下方向进一步改进：

- **项目一：**尝试 XGBoost、LightGBM 等更强的梯度提升模型；采用 SMOTE 等过采样方法更充分地处理类别不平衡；引入特征工程（如特征交互、分箱）与特征选择以提升判别力；也可尝试将质量评分作为回归任务建模后再分级。

- **项目二**：引入数据增强（随机裁剪、翻转、旋转）以抑制过拟合并提升泛化；用批归一化（BatchNorm）替代 LRN 以加速收敛、稳定训练；适当增加训练轮数并采用余弦退火等更精细的学习率策略；亦可对比 VGG、ResNet 等更先进的网络结构，分析深度对精度的影响。
- **通用**：建立更系统的实验管理与超参数搜索流程，对关键结果进行多次重复实验以评估稳定性，并引入更全面的可视化与误差分析手段。

参考文献

- [1] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 2012: 1097–1105.
- [2] Cortez P, Cerdeira A, Almeida F, et al. Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 2009, 47(4): 547–553.
- [3] Xiao H, Rasul K, Vollgraf R. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv:1708.07747*, 2017.
- [4] Breiman L. Random Forests. *Machine Learning*, 2001, 45(1): 5–32.
- [5] Cortes C, Vapnik V. Support-Vector Networks. *Machine Learning*, 1995, 20(3): 273–297.
- [6] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 2011, 12: 2825–2830.
- [7] Paszke A, Gross S, Massa F, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. *NeurIPS*, 2019: 8024–8035.