

本科毕业论文（设计）

# 人工智能综合实训 II

## 实 训 报 告

题    目：    机器学习与手写 AlexNet 图像分类

学    院：    人工智能与低空技术学院

专    业：    人工智能

小组成员：    雷正（202434610309）、蔡铭飞（202434610301）、  
                    冼嘉谦（202434610326）

指导教师：    赵静

提交日期：    2026 年 6 月

## 华南农业大学本科毕业论文（设计）原创性声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名：\_\_\_\_\_ 日期： 年 月 日

## 华南农业大学本科毕业论文（设计）使用授权声明

本人完全了解学校有关保留、使用毕业论文（设计）的规定，同意学校保留并向国家有关部门或机构送交毕业论文（设计）的复印件和电子版，允许毕业论文（设计）被查阅和借阅。学校可以将本毕业论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编毕业论文（设计）。

作者签名：\_\_\_\_\_ 指导教师签名：\_\_\_\_\_  
日期： 年 月 日 日期： 年 月 日

## 摘 要

随着人工智能技术的迅速发展,机器学习已成为数据分析与智能决策的核心工具。本实训围绕“机器学习全流程实践”展开,完成两个相互独立又层层递进的项目,系统覆盖结构化数据建模与图像深度学习两大方向。**项目一**面向结构化数据,在 UCI 白葡萄酒质量数据集上构建多分类模型,系统对比了支持向量机、决策树、随机森林与逻辑回归四种算法,采用网格搜索与五折交叉验证进行超参数寻优,并使用准确率、精确率、召回率、宏平均 F1 等指标进行评估。实验结果表明,集成学习方法随机森林取得最佳性能,测试集准确率 73.5%、宏平均 F1 为 0.734,显著优于线性模型。**项目二**面向图像数据,依据经典论文逐层手工实现卷积神经网络 AlexNet (不调用任何预置模型),在 Fashion-MNIST 数据集上完成十分类任务,经 BatchNorm、余弦退火与数据增强充分训练后,测试准确率达 **94.38%**。在此基础上,本文进一步提出“**诊断—改进—验证**”的误差驱动方法论:项目一据“邻级混淆”改用有序回归分级,将严重误判减少 43%;项目二通过组件消融与 Grad-CAM 可解释性分析,定量厘清 BatchNorm、训练时长与数据增强各自的贡献,并据此否证了 Focal Loss 在本任务上的适用性。两个项目完整覆盖了数据加载、可视化、预处理、建模、评估与结论的全流程,验证了集成学习在结构化数据上的优势与深度卷积神经网络在图像识别上的有效性,并通过对照与消融实验积累了模型调优与工程实现的经验。

**关键词:** 机器学习; 支持向量机; 随机森林; 卷积神经网络; AlexNet; 图像分类

# 目录

|                                    |           |
|------------------------------------|-----------|
| <b>1 引言</b>                        | <b>5</b>  |
| 1.1 研究背景与意义 . . . . .              | 5         |
| 1.2 国内外研究现状 . . . . .              | 5         |
| 1.3 项目研究思路 . . . . .               | 5         |
| 1.4 小组成员分工 . . . . .               | 6         |
| <b>2 相关理论基础</b>                    | <b>6</b>  |
| 2.1 监督学习与分类问题 . . . . .            | 6         |
| 2.2 传统机器学习算法 . . . . .             | 7         |
| 2.2.1 支持向量机 (SVM) . . . . .        | 7         |
| 2.2.2 决策树 . . . . .                | 7         |
| 2.2.3 随机森林 . . . . .               | 7         |
| 2.2.4 逻辑回归 . . . . .               | 7         |
| 2.3 卷积神经网络与 AlexNet . . . . .      | 7         |
| 2.4 模型评估指标 . . . . .               | 8         |
| 2.5 实验环境配置 . . . . .               | 8         |
| <b>3 项目一：红酒质量分类</b>                | <b>9</b>  |
| 3.1 数据集介绍与来源 . . . . .             | 9         |
| 3.2 数据加载与可视化分布 . . . . .           | 9         |
| 3.3 数据预处理 . . . . .                | 10        |
| 3.4 模型建立 . . . . .                 | 11        |
| 3.5 模型评估 . . . . .                 | 12        |
| 3.6 误差分析 . . . . .                 | 15        |
| 3.7 本章小结 . . . . .                 | 15        |
| <b>4 项目二：手写 AlexNet 图像分类</b>       | <b>15</b> |
| 4.1 数据集介绍与来源 . . . . .             | 15        |
| 4.2 数据加载与可视化 . . . . .             | 16        |
| 4.3 数据预处理 . . . . .                | 16        |
| 4.4 模型建立 . . . . .                 | 16        |
| 4.5 模型评估 . . . . .                 | 18        |
| 4.6 设计组件的对照实验（固定 15 轮预算） . . . . . | 20        |
| 4.7 训练效率与计算复杂度 . . . . .           | 22        |
| 4.8 误差分析 . . . . .                 | 22        |
| 4.9 架构对照拓展：训练技巧的尽头与更优架构 . . . . .  | 23        |
| 4.10 本章小结 . . . . .                | 24        |

5 核心创新：误差驱动的对针对性改进 24

5.1 项目一改进：从分类到有序回归 25

5.2 项目二的组件贡献消融：拆解 94.38% 的来源 25

5.3 对照与可解释性分析：为什么是 BatchNorm 而非 Focal Loss 26

5.4 本章小结 27

6 实验复现说明 27

6.1 代码文件说明 27

6.2 运行步骤与关键设置 28

7 结论与实验总结 28

7.1 结论 28

7.2 实验总结 29

7.3 改进方案 29

参考文献 29

# 1 引言

## 1.1 研究背景与意义

人工智能是研究、开发用于模拟和扩展人类智能的理论、方法与技术的科学，而机器学习作为其最重要的分支，致力于让计算机系统通过经验（数据）自动改善性能，而无需被显式编程。近年来，得益于数据规模的爆炸式增长与计算硬件（尤其是 GPU）的进步，机器学习在图像识别、自然语言处理、推荐系统、医疗诊断等众多领域取得了突破性进展，深刻改变了人们的生产与生活方式。

按照数据形态的不同，机器学习任务大致可分为两类：一类是面向结构化（表格）数据的任务，典型如分类与回归，通常采用支持向量机、决策树、集成学习等传统算法；另一类是面向图像、语音、文本等非结构化数据的任务，主要依赖深度神经网络。本实训分别选取这两类任务的代表性问题——红酒质量分级与服饰图像分类，通过完整的工程实践，加深对机器学习核心思想、典型算法与建模流程的理解，培养从数据到模型、再到结论的综合实践能力，具有重要的学习与应用价值。

## 1.2 国内外研究现状

在传统机器学习方面，支持向量机由 Cortes 和 Vapnik (1995) 正式提出，凭借坚实的统计学习理论基础和优秀的小样本泛化能力，长期是分类任务的重要工具；以随机森林 (Breiman, 2001)、梯度提升树 (GBDT、XGBoost、LightGBM) 为代表的集成学习方法，通过组合多个弱学习器进一步提升了精度与鲁棒性，至今仍是结构化数据竞赛中的主流方案。在深度学习方面，Krizhevsky 等 (2012) 提出的 AlexNet 在 ImageNet 竞赛中以显著优势夺冠，掀起了深度卷积网络的研究热潮；此后 VGG (Simonyan 和 Zisserman, 2015)、GoogLeNet、ResNet (He 等, 2016) 等更深、更高效的网络结构相继涌现，不断刷新图像识别的精度上限。本实训以经典且最具代表性的 AlexNet 为研究对象，逐层复现其结构，旨在透彻理解卷积神经网络的工作机制。

## 1.3 项目研究思路

本实训采用统一的机器学习方法论，对两个项目均遵循如下六个环节循序推进，整体流程如图 1.1 所示：

- (1) **数据加载**：从公开数据源获取数据集，读入内存并核对规模、字段与完整性；
- (2) **数据查看**：通过描述性统计与可视化了解数据分布、相关性与潜在问题；
- (3) **数据预处理**：包括标签构造、特征标准化、数据集划分以及类别不平衡处理；
- (4) **模型建立**：根据任务特点选择合适的算法或网络结构，并通过调参确定最优配置；
- (5) **模型评估**：在独立测试集上用多种指标量化性能，并借助混淆矩阵等工具深入分析；
- (6) **结论分析**：归纳实验结果，对比模型优劣，总结经验并提出改进方案。



图 1.1 本组两个子项目的总体技术路线

## 1.4 小组成员分工

本项目由小组协作完成，成员分工如表 1.1 所示。

表 1.1 小组成员分工表

| 学号           | 姓名  | 主要分工                        |
|--------------|-----|-----------------------------|
| 202434610309 | 雷正  | 项目一数据预处理与机器学习建模、调参与评估       |
| 202434610301 | 蔡铭飞 | 项目二 AlexNet 网络实现、模型训练与可视化评估 |
| 202434610326 | 冼嘉谦 | 数据可视化、报告撰写、PPT 制作与汇报        |

## 2 相关理论基础

### 2.1 监督学习与分类问题

监督学习是机器学习中最常见的范式，其任务是在给定带标签的训练集  $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$  上学习一个映射  $f: \mathcal{X} \rightarrow \mathcal{Y}$ ，使其对未知样本具有良好的预测能力。当标签  $y$  取离散值时即为**分类问题**。本实训两个项目均属于多分类问题：项目一为三分类（红酒质量等级），项目二为十分类（服饰类别）。模型学习的核心是最小化训练数据上的损失函数，同时通过正则化、交叉验证等手段控制模型复杂度以提升泛化能力（周志华, 2016）。

## 2.2 传统机器学习算法

### 2.2.1 支持向量机 (SVM)

支持向量机的基本思想是在特征空间中寻找一个最大间隔超平面以分隔不同类别。其优化目标为：

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i, \quad \text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0, \quad (2.1)$$

其中  $C$  为惩罚系数,  $\xi_i$  为松弛变量。对于非线性可分问题, SVM 通过核函数将样本映射到高维空间, 本实训采用径向基 (RBF) 核:  $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$ 。

### 2.2.2 决策树

决策树通过递归地选择最优特征对样本空间进行划分, 形成树状的判别结构。划分依据通常为基尼不纯度:

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2, \quad (2.2)$$

其中  $p_k$  为类别  $k$  在节点中的占比 (周志华, 2016)。算法每次选择使子节点不纯度下降最大的特征进行分裂, 具有良好的可解释性, 但单棵树容易过拟合。

### 2.2.3 随机森林

随机森林 (Breiman, 2001) 是一种基于 Bagging 思想的集成学习方法, 通过自助采样 (Bootstrap) 构建多棵决策树, 并在每次分裂时随机选取部分特征, 最后对所有树的预测结果进行多数表决:

$$\hat{y} = \text{mode}\{T_1(\mathbf{x}), T_2(\mathbf{x}), \dots, T_M(\mathbf{x})\}. \quad (2.3)$$

随机性的引入降低了模型方差, 使其在保持高精度的同时具有较强的抗过拟合能力。

### 2.2.4 逻辑回归

逻辑回归是一种线性分类模型, 通过 Softmax (多分类) 函数将线性输出映射为类别概率:

$$P(y = k | \mathbf{x}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x})}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x})}, \quad (2.4)$$

并以交叉熵为损失函数进行参数估计 (周志华, 2016)。其结构简单、训练高效, 常作为分类任务的基线模型。

## 2.3 卷积神经网络与 AlexNet

卷积神经网络 (CNN) 是处理图像数据的主流深度模型, 其核心组件包括:

- **卷积层**：通过可学习的卷积核在图像上滑动提取局部特征，具有局部连接与权值共享的特点，大幅减少参数量。给定输入尺寸  $W$ 、卷积核  $K$ 、步长  $S$ 、填充  $P$ ，输出尺寸为  $O = \lfloor (W - K + 2P)/S \rfloor + 1$ 。
- **激活函数 ReLU**： $f(x) = \max(0, x)$ ，引入非线性并缓解梯度消失，是 AlexNet 的关键创新之一。
- **池化层**：通过最大池化等操作进行下采样，降低特征图尺寸、增强平移不变性。
- **局部响应归一化 (LRN)**：对相邻通道的响应进行归一化，增强模型的泛化能力。
- **Dropout**：训练时以一定概率随机置零神经元输出，有效抑制过拟合 (Srivastava 等, 2014)。
- **全连接层**：将提取到的高层特征映射到类别空间，输出分类结果。

AlexNet(Krizhevsky 等, 2012) 由 5 个卷积层与 3 个全连接层堆叠而成，首次将 ReLU、Dropout、数据增强与 GPU 训练有机结合，是深度学习发展史上的里程碑。

## 2.4 模型评估指标

对于分类任务，依据混淆矩阵中的真正例 TP、假正例 FP、真负例 TN、假负例 FN，常用指标定义如下：

$$\text{准确率} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{精确率} = \frac{TP}{TP + FP}, \quad \text{召回率} = \frac{TP}{TP + FN}, \quad (2.5)$$

$$F1 = \frac{2 \cdot \text{精确率} \cdot \text{召回率}}{\text{精确率} + \text{召回率}}. \quad (2.6)$$

对于多分类问题，常计算各类别指标的算术平均，即**宏平均** (Macro-average)，它对每个类别一视同仁，能更好地反映模型在不平衡数据上的综合表现 (周志华, 2016)。混淆矩阵则以矩阵形式展示各类别的预测分布，可直观分析模型的混淆情况。

## 2.5 实验环境配置

本实训的全部实验均在同一硬件与软件环境下完成，具体配置如表 2.1 所示。项目一的机器学习模型基于 scikit-learn(Pedregosa 等, 2011) 实现，项目二的 AlexNet 基于 PyTorch(Paszke 等, 2019) 实现并使用 GPU 加速训练。

表 2.1 实验环境配置

| 项目     | 配置                                             |
|--------|------------------------------------------------|
| 操作系统   | Linux (Ubuntu)                                 |
| 编程语言   | Python 3.12                                    |
| 深度学习框架 | PyTorch 2.7.1 (CUDA 11.8) + torchvision 0.22.1 |
| 机器学习库  | scikit-learn 1.8.0                             |
| 数据处理   | pandas 3.0.2、numpy 2.4.3                       |
| 可视化    | matplotlib 3.10.8、seaborn                      |
| GPU    | NVIDIA GeForce RTX 4090 (24GB)                 |

### 3 项目一：红酒质量分类

#### 3.1 数据集介绍与来源

本项目采用 **UCI 机器学习仓库**公开的葡萄酒质量数据集 (Wine Quality Data Set) (Cortez 等, 2009), 来源网址为 <https://archive.ics.uci.edu/dataset/186/wine+quality>。其中白葡萄酒子集共 **4898** 个样本, 每个样本包含 **11** 个理化特征以及 1 个质量评分标签 (0–10 的整数, 由品酒师综合评定)。各特征的含义如表 3.1 所示。

表 3.1 白葡萄酒数据集特征说明

| 特征                  | 含义         | 特征                   | 含义        |
|---------------------|------------|----------------------|-----------|
| fixed acidity       | 固定酸度 (酒石酸) | total sulfur dioxide | 总二氧化硫     |
| volatile acidity    | 挥发性酸度 (醋酸) | density              | 密度        |
| citric acid         | 柠檬酸        | pH                   | 酸碱度       |
| residual sugar      | 残糖         | sulphates            | 硫酸盐       |
| chlorides           | 氯化物        | alcohol              | 酒精度       |
| free sulfur dioxide | 游离二氧化硫     | quality              | 质量评分 (标签) |

#### 3.2 数据加载与可视化分布

数据以分号分隔的 CSV 文件存储, 使用 `pandas` 读入后核验为  $4898 \times 12$  (11 特征 + 1 标签), 经检查无缺失值与重复值, 数据质量良好。为深入理解数据特性, 绘制了质量评分的分布直方图 (图 3.1) 与特征相关性热力图 (图 3.2)。




图 3.1 葡萄酒质量评分分布

由分布图可见，质量评分高度集中于 5、6、7 三档，评分为 6 的样本最多，而极高（8、9）与极低（3、4）评分的样本极少，整体呈现明显的“中间多、两端少”的长尾不平衡特征，这给少数类的识别带来了挑战。由相关性热力图（图 3.2）可见，酒精度（alcohol）与质量评分呈较强的正相关，而密度（density）与质量评分呈负相关，二者本身又高度负相关；这与酿酒学常识一致——酒精度越高往往口感越佳，表明所选特征对质量判别具备一定的有效信息。




图 3.2 特征相关性热力图

### 3.3 数据预处理

针对原始数据与任务特点，进行如下预处理：

- (1) **标签构造**: 原始质量评分有 7 个取值且极不均衡, 直接做七分类意义有限。故将其分箱为三个等级——评分  $\leq 5$  记为“差”(类 0)、 $= 6$  记为“中”(类 1)、 $\geq 7$  记为“好”(类 2)。分箱后三类样本数分别为 1640、2198、1060, 更符合实际的质量分级需求。
- (2) **特征标准化**: 由于各特征量纲差异较大(如 total sulfur dioxide 可达上百, 而 density 接近 1), 采用  $z = (x - \mu)/\sigma$  对 11 个特征进行零均值、单位方差标准化。标准化参数仅在训练集上拟合后再应用到测试集, 以严格避免数据泄漏。
- (3) **数据集划分**: 按 8:2 进行分层抽样划分, 得到训练集 3918 个、测试集 980 个样本, 分层抽样保证训练集与测试集中各类别比例与总体一致。
- (4) **不平衡处理**: 考虑到类别不平衡, 所有模型统一设置 `class_weight='balanced'`, 按类别频率的反比为样本加权, 使模型更关注少数类, 避免被多数类主导。

关于标签分箱的依据, 表 3.2 给出了原始质量评分的完整分布及三分类归并方案。

表 3.2 原始质量评分分布与三分类归并方案

| 原始评分 | 3                    | 4   | 5    | 6       | 7                    | 8   | 9 | 合计   |
|------|----------------------|-----|------|---------|----------------------|-----|---|------|
| 样本数  | 20                   | 163 | 1457 | 2198    | 880                  | 175 | 5 | 4898 |
| 归并类别 | 差 ( $\leq 5$ ): 1640 |     |      | 中: 2198 | 好 ( $\geq 7$ ): 1060 |     |   |      |

如表 3.2 所示, 原始评分高度集中于 5、6、7 三档(合计占 92.6%), 而 3、4、8、9 分的样本极少(最少的 9 分仅 5 例)。若直接进行七分类, 这些极少数类几乎无法被有效学习、评价也极不稳定; 而若简化为二分类, 又会丢失“中等品质”这一重要档次。因此, 本文参照课程“3 分类”要求并结合数据的实际分布, 将评分按  $\leq 5 / = 6 / \geq 7$  归并为差/中/好三类——这样既保证了每个类别都有足够的样本量(最少 1060 例), 又符合葡萄酒质量“低/中/高”分级的实际语义, 是兼顾可学习性与业务含义的合理选择。

### 3.4 模型建立

项目一的完整建模流程如图 3.3 所示: 经数据集导入、探索性数据分析、任务定义与分层划分后, 以 Pipeline 将标准化与分类器封装为一体, 再通过 GridSearchCV 完成交叉验证调参, 最终对四种模型做统一评估。




图 3.3 项目一传统机器学习建模流程

选取支持向量机、决策树、随机森林、逻辑回归四种代表性算法（原理见 2.2 节），借助 scikit-learn (Pedregosa 等, 2011) 提供的 GridSearchCV，通过五折交叉验证结合网格搜索（评分准则为宏平均 F1）对关键超参数进行寻优，各模型的搜索空间与最优结果见表 3.3。五折交叉验证将训练集均分为五份，轮流以其中四份训练、一份验证，取平均性能作为该超参数组合的评分，从而更稳健地选择超参数、降低过拟合风险。

表 3.3 四种模型的搜索空间与最优超参数

| 模型   | 主要搜索空间                                                         | 最优超参数                     |
|------|----------------------------------------------------------------|---------------------------|
| SVM  | $C \in \{1, 10\}$ , $\gamma \in \{\text{scale}, 0.1\}$ , RBF 核 | $C = 10$ , $\gamma = 0.1$ |
| 决策树  | 最大深度 $\in \{\text{None}, 10, 20\}$ , 叶子最小样本 $\in \{1, 5\}$     | 深度 None, 叶子 1             |
| 随机森林 | 树数 $\in \{200, 400\}$ , 最大深度 $\in \{\text{None}, 20\}$         | 树数 200, 深度 20             |
| 逻辑回归 | $C \in \{0.5, 1, 10\}$                                         | $C = 0.5$                 |

### 3.5 模型评估

在独立测试集上对四个模型进行评估，整体指标对比见表 3.4 与图 3.4。

表 3.4 四种机器学习模型测试集性能对比

| 模型          | 准确率          | 精确率          | 召回率          | 宏平均 F1       |
|-------------|--------------|--------------|--------------|--------------|
| SVM         | 0.617        | 0.616        | 0.660        | 0.622        |
| 决策树         | 0.650        | 0.647        | 0.644        | 0.645        |
| <b>随机森林</b> | <b>0.735</b> | <b>0.748</b> | <b>0.723</b> | <b>0.734</b> |
| 逻辑回归        | 0.522        | 0.524        | 0.567        | 0.520        |




图 3.4 四种传统机器学习模型测试集 Accuracy 与 Macro-F1 对比

考虑到本任务**标签有序且类别不平衡**，仅凭准确率与宏 F1 难以全面刻画模型质量，因此进一步报告五项进阶指标（表 3.5）：**平衡准确率**（各类召回率的均值，抗类别不平衡）、**二次加权 Kappa (QWK)**（对“跨级”错误施以二次方惩罚的有序一致性指标）、**Cohen’s Kappa**（排除随机猜测后的一致性）、**Matthews 相关系数 (MCC)**（不平衡场景下稳健的综合相关度）与**宏平均 ROC-AUC**（一对其余 OvR，衡量概率排序质量）。

表 3.5 四种模型的进阶评估指标（测试集）

| 模型          | 平衡准确率        | 二次加权 Kappa   | Cohen’s Kappa | MCC          | 宏 ROC-AUC    |
|-------------|--------------|--------------|---------------|--------------|--------------|
| SVM         | 0.660        | 0.626        | 0.428         | 0.439        | 0.819        |
| 决策树         | 0.644        | 0.566        | 0.451         | 0.452        | 0.729        |
| <b>随机森林</b> | <b>0.724</b> | <b>0.720</b> | <b>0.579</b>  | <b>0.581</b> | <b>0.899</b> |
| 逻辑回归        | 0.567        | 0.491        | 0.296         | 0.311        | 0.740        |

在全部五项进阶指标上随机森林**依然稳居第一**（尤以 QWK 0.720、宏 ROC-AUC 0.899 明显领先），说明其优势是跨“一致性—概率排序—抗不平衡”多维度的全面领先，而非某一指标的偶然；逻辑回归各项垫底，与其线性假设难以拟合理化指标到质量之间的非线性关系相符。

由表 3.4 可见，随机森林在四项指标上全面领先，其次为决策树与 SVM，逻辑回归表现最差。为进一步分析最优模型，给出随机森林各类别的详细指标（表 3.6）及其混淆矩阵（图 3.5）。

表 3.6 随机森林各类别精确率/召回率/F1

| 类别             | 精确率  | 召回率  | F1   | 样本数 |
|----------------|------|------|------|-----|
| 差 ( $\leq 5$ ) | 0.78 | 0.73 | 0.76 | 328 |
| 中 ( $= 6$ )    | 0.69 | 0.77 | 0.73 | 440 |
| 好 ( $\geq 7$ ) | 0.77 | 0.67 | 0.72 | 212 |

从各类别指标看，随机森林对“差”“好”两端类别的精确率较高，而“中”类样本最多、与相邻等级边界模糊，召回率虽高但精确率相对偏低，这与质量评分本身的连续性、相邻等级难以截然区分的特点相符。




图 3.5 随机森林混淆矩阵

此外，随机森林可输出特征重要性（图 3.6），结果显示酒精度、密度与挥发性酸度对质量判别贡献最大，与相关性分析的结论相互印证。




图 3.6 随机森林特征重要性排序

### 3.6 误差分析

进一步分析随机森林的混淆矩阵（图 3.5）可以发现，模型的误差呈现明显的“**邻级混淆**”特征：真实为“差”的 328 个样本中有 82 个被误判为“中”，真实为“好”的 212 个样本中有 68 个被误判为“中”，而“差”与“好”两个相隔等级之间的相互误判极少（分别仅 5 例与 2 例）。其根源在于，质量评分本质上是连续的有序变量，相邻等级（如 5 分与 6 分）的样本在理化特征上高度接近，缺乏清晰的判别边界；而处于中间的“中”类样本数量最多、左右毗邻两端，自然成为误判的主要汇聚点。这提示我们：若将该问题建模为有序回归（Ordinal Regression）或引入对邻级错误更敏感的代价矩阵，有望进一步降低此类误差。

### 3.7 本章小结

实验表明，随机森林在所有指标上均显著领先，宏平均 F1 达 0.734，比次优的决策树高出约 9 个百分点；逻辑回归作为线性模型表现最差（F1 仅 0.520），说明该任务中特征与质量之间存在较强的非线性关系，线性模型难以刻画，而集成学习能更好地拟合复杂的决策边界，并通过多树投票降低方差、提升鲁棒性。特征重要性进一步揭示了影响葡萄酒质量的关键理化指标，体现了机器学习模型在数据分析中的可解释价值。

## 4 项目二：手写 AlexNet 图像分类

### 4.1 数据集介绍与来源

本项目采用 **Fashion-MNIST** 数据集 (Xiao 等, 2017)，由德国 Zalando 公司发布，来源网址为 <https://www.kaggle.com/datasets/zalando-research/fashionmnist> (亦可经 torchvision 自动下载)。数据集共 **70000** 张  $28 \times 28$  的灰度服饰图像，其中训练集 60000 张、测试集 10000 张，均匀覆盖 10 个类别：T 恤、裤子、套衫、连衣裙、外套、凉

鞋、衬衫、运动鞋、包、短靴。相比经典的手写数字 MNIST，Fashion-MNIST 类间相似度更高、纹理更复杂、识别难度更大，已成为评估图像分类算法的标准基准数据集之一。

## 4.2 数据加载与可视化

通过 `torchvision.datasets.FashionMNIST` 接口自动下载并加载数据。由于 AlexNet 的标准输入为  $224 \times 224$ ，在加载时通过 `Resize` 将原始  $28 \times 28$  图像放大至  $224 \times 224$ 。部分测试样例及其预测结果如图 4.5 所示（绿色标题表示预测正确，红色表示预测错误），可见模型对大多数样本判别准确，仅在视觉相似的上装类别间偶有混淆。

## 4.3 数据预处理

图像预处理流程包括：(1) `Resize(224)` 将图像缩放到网络所需尺寸；(2) `ToTensor` 将像素值转为张量并归一化到  $[0,1]$ ；(3) `Normalize` 按 Fashion-MNIST 的单通道均值 0.2860、标准差 0.3530 进行标准化，使输入分布更利于网络收敛。此外，从 60000 张训练图中随机划出 10% 作为验证集用于训练过程中的模型选择（保存验证集表现最优的模型），最终在独立的 10000 张测试图上评估。

## 4.4 模型建立

按照经典 AlexNet 论文，使用 `nn.Conv2d`、`nn.MaxPool2d`、`nn.Linear` 等基础算子 **逐层手工搭建网络**，**不调用** `torchvision.models` 中的任何预置 AlexNet。网络输入为  $1 \times 224 \times 224$  的灰度图，由 5 个卷积块与 3 个全连接层构成，各层配置与输出尺寸见表 4.1，总参数量约 58.3M。其中卷积层负责逐级提取由边缘、纹理到语义部件的层次化特征，池化层逐步降低空间分辨率，全连接层完成最终的类别判别。每个卷积层后均接入**批归一化 (BatchNorm)** 以稳定各层输入分布、加速收敛；原始 AlexNet 使用的局部响应归一化 (LRN) 则作为对照在第 4.6 节单独消融。网络整体结构与各层张量尺寸的演变如图 4.1 所示，可与表 4.1 的逐层参数相互对照。




图 4.1 手写 AlexNet 网络结构示意图

表 4.1 手写 AlexNet 网络结构

| 层        | 配置                                         | 输出尺寸                      |
|----------|--------------------------------------------|---------------------------|
| 输入       | 灰度图像                                       | $1 \times 224 \times 224$ |
| Conv1    | 96 核, $11 \times 11$ , 步长 4, 填充 2; BN+ReLU | $96 \times 55 \times 55$  |
| MaxPool1 | $3 \times 3$ , 步长 2                        | $96 \times 27 \times 27$  |
| Conv2    | 256 核, $5 \times 5$ , 填充 2; BN+ReLU        | $256 \times 27 \times 27$ |
| MaxPool2 | $3 \times 3$ , 步长 2                        | $256 \times 13 \times 13$ |
| Conv3    | 384 核, $3 \times 3$ , 填充 1; BN+ReLU        | $384 \times 13 \times 13$ |
| Conv4    | 384 核, $3 \times 3$ , 填充 1; BN+ReLU        | $384 \times 13 \times 13$ |
| Conv5    | 256 核, $3 \times 3$ , 填充 1; BN+ReLU        | $256 \times 13 \times 13$ |
| MaxPool3 | $3 \times 3$ , 步长 2                        | $256 \times 6 \times 6$   |
| 全连接 FC6  | Dropout(0.5) + Linear; ReLU                | 4096                      |
| 全连接 FC7  | Dropout(0.5) + Linear; ReLU                | 4096                      |
| 全连接 FC8  | Linear (输出层)                               | 10                        |

**训练配置：**损失函数采用交叉熵  $L = -\sum_i y_i \log \hat{y}_i$ ；优化器为带动量的随机梯度下降（SGD，动量 0.9，权重衰减  $5 \times 10^{-4}$ ），其更新规则为  $v \leftarrow \beta v - \eta \nabla L$ ,  $\theta \leftarrow \theta + v$ ，动量项有助于加速收敛并抑制震荡；初始学习率 0.01，采用**余弦退火**（CosineAnnealingLR）将学习率沿余弦曲线平滑衰减至 0，相比阶梯式衰减更适合较长训练；批大小 128，共训练 **40 轮**，并对训练集施加**数据增强**（随机水平翻转 + 小角度旋转）以提升泛化能力，按验证集准确率保存最优模型。训练在单张 NVIDIA RTX 4090 GPU 上完成，约耗时半小

时。这些设置并非随意选定，而是由第 4.6 节的组件对照实验逐一验证后确定（详见第五章的贡献消融分析）。

项目二从数据准备到最终评估的完整流程如图 4.2 所示，分为数据准备、模型训练、模型选择与最终评估可视化四个阶段：数据准备完成训练/验证/测试划分、Resize 与标准化；模型训练以手写 AlexNet 配合交叉熵损失、SGD-动量优化器与学习率调度推进；模型选择按验证集准确率保存最优权重；最终评估在测试集上计算 Accuracy 与 Macro-F1，并辅以混淆矩阵与 Grad-CAM 可视化。




图 4.2 项目二 AlexNet 训练与评估流程

#### 4.5 模型评估

训练与验证过程的损失、准确率曲线见图 4.3。可见训练初期损失迅速下降、准确率快速提升；随着余弦退火使学习率平滑衰减，后期曲线稳步逼近最优，验证集最高准确率达 **0.9457**。训练末期训练准确率约 0.975、验证约 0.945，两者仅存约 3 个百分点的良性差距，未见明显过拟合，表明 BatchNorm、Dropout、权重衰减与数据增强共同构成了有效的正则化，模型在 40 轮内得到了充分而稳定的训练。




图 4.3 AlexNet 训练/验证损失与准确率曲线

在 10000 张测试图像上，模型最终准确率为 **94.38%**，宏平均精确率、召回率、F1 分别为 0.9437、0.9438、0.9437。除硬分类指标外，模型的**宏平均 ROC-AUC 高达 0.9972**，**Cohen’s Kappa 与 MCC 均为 0.938**，表明其在概率排序质量与“排除随机猜测”的一致性上同样表现优异（10 类近乎均衡，故各项与准确率高度吻合）。各类别详细指标见表 4.2，整体混淆情况见图 4.4。

表 4.2 AlexNet 各类别测试指标

| 类别  | 精确率  | 召回率  | F1   | 类别  | 精确率  | 召回率  | F1   |
|-----|------|------|------|-----|------|------|------|
| T 恤 | 0.90 | 0.90 | 0.90 | 凉鞋  | 0.99 | 0.99 | 0.99 |
| 裤子  | 1.00 | 0.99 | 1.00 | 衬衫  | 0.84 | 0.82 | 0.83 |
| 套衫  | 0.93 | 0.91 | 0.92 | 运动鞋 | 0.96 | 0.98 | 0.97 |
| 连衣裙 | 0.94 | 0.94 | 0.94 | 包   | 0.99 | 0.99 | 0.99 |
| 外套  | 0.90 | 0.94 | 0.92 | 短靴  | 0.98 | 0.97 | 0.97 |




图 4.4 AlexNet 测试集混淆矩阵




图 4.5 测试集预测样例（绿色为正确，红色为错误）

#### 4.6 设计组件的对照实验（固定 15 轮预算）

上节主模型的若干设计（去除 LRN、是否数据增强、网络容量）并非凭经验拍定，而是先通过一组 **低成本对照** 快速筛选。为公平比较，这些对照统一采用一个 **刻意压缩的 15 轮训练预算**（其余协议相同：SGD、批大小 128），用较小的算力代价隔离出每个组件的单独作用；需强调的是，15 轮仅是 **对照用的短预算**，并非主模型的训练设置（主模型为 40 轮）。结果如表 4.3 与图 4.6 所示。其中 SimpleCNN 为仅含 3 个卷积块的轻量网络（约 0.39M 参数，直接在  $28 \times 28$  原图上训练，重复 3 个随机种子取均值  $\pm$  标准差）；AlexNet 则分别测试了含 LRN 的版本、去掉 LRN 的版本，以及在该短预算下分别加入数据增强、标签平滑的版本。

表 4.3 Fashion-MNIST 上的设计组件对照实验结果（固定 15 轮预算）

| 模型 / 配置                                 | 参数量   | 测试准确率               | 宏平均 F1              |
|-----------------------------------------|-------|---------------------|---------------------|
| SimpleCNN（轻量基线，3 种子）                    | 0.39M | $0.9181 \pm 0.0015$ | $0.9171 \pm 0.0014$ |
| AlexNet（基线：LRN，无增强）                     | 58.3M | 0.9183              | 0.9179              |
| <b>AlexNet（消融：去掉 LRN）</b>               | 58.3M | <b>0.9247</b>       | <b>0.9245</b>       |
| AlexNet（+ 数据增强）                         | 58.3M | 0.9106              | 0.9103              |
| AlexNet（去 LRN + 标签平滑 $\epsilon = 0.1$ ） | 58.3M | 0.9226              | 0.9224              |




图 4.6 不同模型/配置的测试集准确率对比 (SimpleCNN 误差棒为 3 个种子的标准差)

对照实验得到三点有价值的结论：

(1) **模型容量应与数据复杂度相匹配**。仅 0.39M 参数的 SimpleCNN 达到了 0.9181 的准确率，与 58.3M 参数的 AlexNet (0.9183) 几乎持平。这说明 Fashion-MNIST 本身信息量有限，AlexNet 巨大的参数量在该任务上存在明显冗余；课程要求复现 AlexNet 具有教学价值，但从工程角度看，轻量网络才是该数据集更高性价比的选择。这也解释了为何本任务无需依赖巨大的全连接层。

(2) **LRN 并非必要，去掉反而更优**。去掉 LRN 后 AlexNet 准确率由 0.9183 提升至 0.9247，与深度学习的发展趋势一致——LRN 在后续的 VGG、ResNet 等网络中已被批归一化 (BatchNorm, Ioffe 和 Szegedy, 2015) 取代，表明其正则化收益有限，在小数据上甚至可能干扰特征表达。

(3) **数据增强的收益依赖训练预算**。在该 15 轮短预算下，加入随机翻转与旋转后准确率反降至 0.9106——增强增加了优化难度而模型尚未充分收敛。但这并不意味着增强无用：当训练预算放宽到 40 轮后，同样的增强转为**正收益**（详见第 5.2 节的贡献消融）。这一“增强 × 训练时长”的交互正是本文据以确定主模型配置 (BN + 数据增强 + 40 轮) 的依据，也说明对照实验的价值在于厘清各组件的**适用条件**，而非简单地给出“某组件好/坏”的结论。

(4) **标签平滑在短预算下未见增益**。在去 LRN 配置上加入标签平滑 ( $\epsilon = 0.1$ ) 后准确率为 0.9226，较未加时的 0.9247 反而略降约 0.2 个百分点。这与数据增强的情形一致——标签平滑本质上也是一种正则化，在 15 轮的欠拟合区间内会拖慢收敛；它再次印证“正则化类组件的收益与训练是否充分强相关”，也说明**并非任何常见 trick 都能无条件带来提升**，这与下一章否证 Focal Loss 的结论一脉相承。

## 4.7 训练效率与计算复杂度

除分类性能外，本节从**计算开销**的角度审视所实现的网络，并报告若干工程优化的实测效果。

(1) **计算复杂度对照**。表 4.4 对比了主模型 AlexNet（输入  $224 \times 224$ ）与轻量 SimpleCNN（输入  $28 \times 28$ ）的**参数量、单图浮点运算量（FLOPs）与推理延迟**。AlexNet 的参数量约为 SimpleCNN 的 **149 倍**、FLOPs 约 **135 倍**、CPU 单图推理延迟约 **10 倍**，而二者在 Fashion-MNIST 上的准确率却相近（第 4.6 节）。这从算力角度坐实了前文判断：**AlexNet 在该任务上存在显著的容量与计算冗余**，将  $28 \times 28$  强行上采样到  $224 \times 224$  又进一步放大了卷积层的无效计算；若以部署为目标，轻量网络是性价比更高的选择。

表 4.4 AlexNet 与 SimpleCNN 的计算复杂度对照（batch=1，RTX 4090）

| 模型（输入）                  | 参数量          | FLOPs        | GPU 延迟       | CPU 延迟        | 测试准确率 <sup>†</sup> |
|-------------------------|--------------|--------------|--------------|---------------|--------------------|
| AlexNet ( $224^2$ )     | 58.30 M      | 1063.5 M     | 0.77 ms      | 15.44 ms      | $\approx 0.918$    |
| SimpleCNN ( $28^2$ )    | 0.39 M       | 7.9 M        | 0.45 ms      | 1.50 ms       | $\approx 0.918$    |
| 倍数（AlexNet / SimpleCNN） | $\times 149$ | $\times 135$ | $\times 1.7$ | $\times 10.3$ | —                  |

†：此处为 **15 轮短预算**下两网络的对照精度（约 0.918，见表 4.3）；AlexNet 主模型经 40 轮充分训练后可达 94.38%。FLOPs 由 `thop` 统计单张前向的乘加次数。

(2) **混合精度（AMP）与 cuDNN 自动调优**。引入 `torch.cuda.amp` 自动混合精度（前向与反向以半精度为主、关键处保留单精度，并用 `GradScaler` 防止梯度下溢），配合  `cudnn.benchmark` 在固定输入尺寸下自动挑选最快卷积算法后，主配置下**每轮训练时间由约 12.2s 降至约 10.1s（提速约 1.2 倍、节省约 17%）**，而测试准确率基本不变——半精度未带来可见精度损失。在更深的网络或更大批量下，该加速收益通常会更显著。

(3) **早停（Early Stopping）**。进一步引入基于验证集准确率的早停（耐心 `patience = 5`）：当验证准确率连续 5 轮不再提升即终止训练。在主配置下，模型于**第 26 轮达到验证最优，第 31 轮触发早停**，相比固定 40 轮**节省约 22% 的训练轮数**，对应测试准确率 93.61%。可见早停以约 0.8 个百分点的精度为代价换取了可观的算力节省——这一差距源于余弦退火在最后若干轮（学习率趋近 0）仍能“精修”出少量提升。因此本文的主模型仍采用**完整 40 轮**以追求峰值精度（94.38%），而早停可作为**算力受限场景下的高性价比选项**；二者的取舍取决于对“精度—算力”的偏好。

## 4.8 误差分析

由混淆矩阵（图 4.4）可见，AlexNet 的误差高度集中于四类上装——T 恤、套衫、外套、衬衫之间。其中“衬衫”最难识别，其 1000 个测试样本中虽有 819 个被正确识别，仍有 72 个被误判为 T 恤、55 个误判为外套、35 个误判为套衫；而“T 恤”也有 71 个被误判为衬衫。与之形成鲜明对比的是，“裤子”“包”“凉鞋”“短靴”等形态轮廓差异显著的类别几乎不与其他类别混淆，识别率接近完美。究其原因，这些上装在  $28 \times 28$  的

低分辨率灰度图中，领口、袖型、版型等关键区分性细节被严重弱化，整体轮廓高度相似，是 Fashion-MNIST 的固有难点；预测样例图（图 4.5）中的红色错误样本也大多集中于此类上装。由此可见，进一步提升性能的关键在于增强模型对细粒度纹理的判别能力，例如引入数据增强、更深的网络或注意力机制。

4.9 架构对照拓展：训练技巧的尽头与更优架构

在完成课程规定的手写 AlexNet 主体任务后，我们进一步追问：94.38% 是否已是该任务的上限？为此先**穷尽训练侧的手段**——在主模型基础上叠加 MixUp、随机擦除、标签平滑并延长至 80 轮，测试准确率为 94.45%；再施以测试时增强（TTA，水平翻转平均）与**三模型集成**，准确率最高也仅达 **94.55%**（相对主模型 +0.17 个百分点）。各类正交训练技巧的**边际收益已基本耗尽**，这强烈提示：瓶颈或许**不在训练，而在架构本身**。

事实上，AlexNet 是为  $224 \times 224$  的自然图像设计的：本任务须将  $28 \times 28$  灰度图上**采样 8 倍**（并不增加任何信息）、其  $11 \times 11$  大卷积核与占据绝大部分参数的 4096 维全连接层，对这一简单小图任务而言都**冗余**（详见第 4.7 节）。为验证这一判断，我们**同样逐层手写**了一个小型残差网络（ResNet）作为对照：采用  $3 \times 3$  小卷积核、**残差连接**缓解深层退化、**全局平均池化**替代巨大全连接层，并**直接在原生  $28 \times 28$  上训练**（不做上采样），其余训练协议与 AlexNet 主模型一致。

表 4.5 手写 AlexNet 与手写小型 ResNet 的架构对照（Fashion-MNIST 测试集）

| 指标                  | 手写 AlexNet（主模型）            | 手写小型 ResNet（对照）         |
|---------------------|----------------------------|-------------------------|
| 输入分辨率               | $224 \times 224$ （上采样 8 倍） | $28 \times 28$ （原生）     |
| 参数量                 | 58.30M                     | <b>2.78M</b> （约 1/21）   |
| FLOPs（单图）           | 1063.5M                    | <b>323.3M</b> （约 1/3.3） |
| 测试准确率               | 94.38%                     | <b>94.92%</b>           |
| 验证最高准确率             | 94.57%                     | <b>95.15%</b>           |
| 宏平均 F1              | 0.9437                     | <b>0.949</b>            |
| Cohen's Kappa / MCC | 0.938                      | <b>0.944</b>            |
| “衬衫”类 F1（最难类）       | 0.83                       | <b>0.846</b>            |




图 4.7 架构对照：小型 ResNet 以约 1/21 的参数量反超 AlexNet

结果如表 4.5 与图 4.7 所示：小型 ResNet 在**每一项指标上均超过 AlexNet**（测试准确率 94.38%→94.92%，测试误差相对降低约 10%；连最难的“衬衫”类 F1 也由 0.83 升至 0.846），而其参数量仅为 AlexNet 的**约 1/21**、计算量约 1/3.3。这一对照**实证了前文判断**：限制性能的主要因素是**架构而非训练技巧或数据集天花板**——残差连接、全局平均池化与原生分辨率输入，使一个小得多的网络反而又快又准。需要强调的是，本拓展并非以 ResNet 取代 AlexNet：手写 AlexNet 仍是本项目的规定主体与分析对象，此处的对照旨在**从架构层面理解 AlexNet 的局限**，体现“知其然亦知其所以然”的探究态度。

#### 4.10 本章小结

手写 AlexNet 经 BatchNorm + 余弦退火 + 数据增强充分训练后，在 Fashion-MNIST 上取得了 **94.38%** 的测试准确率，验证了所实现网络的正确性与有效性。从混淆矩阵与各类指标看，“裤子”“包”“凉鞋”“短靴”等形态独特的类别识别率接近完美 ( $F1 \geq 0.97$ )，而“衬衫”类仍是最易混淆者 ( $F1$  约 0.83)，主要与“T 恤”“套衫”“外套”相互误判——这些上装在低分辨率灰度图下轮廓与纹理高度相似，是 Fashion-MNIST 公认的识别难点。各设计组件对该结果的具体贡献，将在第五章通过消融实验进一步定量剖析。此外，第 4.9 节的架构对照表明，在穷尽训练技巧（准确率最高 94.55%）之后，改用手写小型 ResNet 即以约 1/21 的参数反超至 94.92%，揭示出限制 AlexNet 的根本在于其面向大图设计的架构与本任务的不匹配。

### 5 核心创新：误差驱动的针对性改进

本章是本报告的核心创新点。不同于一般实训“跑通模型、报告精度”即止，本文提出并实践一套“**诊断—改进—验证**”闭环方法论：先借助混淆矩阵**诊断**出系统性错误的根因，再针对根因**提出改进方案**，最后用实验**量化验证**改进是否有效。该方法论在两个项目上分别落地。

5.1 项目一改进：从分类到有序回归

**诊断：**由 4.x 与 3.7 节的误差分析可知，红酒任务的误差几乎全部是“邻级混淆”——质量本质是**有序变量**，相邻等级难以区分，而“差 好”这种跨级严重误判极少。**改进：**据此将任务由“直接三分类”改为**有序回归 → 分级**——用随机森林回归器预测连续质量分，再四舍五入归并到差/中/好三级，使模型显式利用等级的有序性。**验证：**除准确率、宏 F1 外，专门引入两个**面向有序性的指标**——“严重误判数”（真实与预测相差 2 级，即差 好的个数）与“有序 MAE”（预测类与真实类之差的平均绝对值）。结果见表 5.1 与图 5.1。

表 5.1 有序回归改进与直接分类的对比

| 方法               | 准确率           | 宏平均 F1        | 二次加权 Kappa    | 严重误判数    | 有序 MAE        |
|------------------|---------------|---------------|---------------|----------|---------------|
| 直接分类（随机森林）       | 0.7347        | 0.7336        | 0.7200        | 7        | 0.2724        |
| <b>有序回归 → 分级</b> | <b>0.7571</b> | <b>0.7533</b> | <b>0.7411</b> | <b>4</b> | <b>0.2469</b> |




图 5.1 有序回归 → 分级显著减少严重误判（差 好）

改进取得了全面提升：准确率由 0.7347 升至 0.7571，宏 F1 由 0.7336 升至 0.7533，二次加权 Kappa 由 0.7200 升至 0.7411，尤其是**严重误判数由 7 降至 4**、有序 MAE 同步下降——QWK 的提升尤其说明改进恰好作用在“跨级错误”这一最该惩罚的维度上。这验证了“显式建模标签的有序性”这一改进思路的有效性，也体现了“从误差分析出发指导建模”的科学方法。

5.2 项目二的组件贡献消融：拆解 94.38% 的来源

第四章的主模型在测试集上达到 94.38%。一个自然的科学问题是：这一性能**分别由哪些设计要素贡献**？为此本节做一组**受控消融**——从一个刻意压缩的最小配置（15 轮、LRN、无增强）出发，逐一加入“更充分的训练”“BatchNorm”“数据增强”三个要素，观察每一步的**边际贡献**，结果见表 5.2 与图 5.2。需要说明的是，最小配置的 15 轮属于欠

**拟合的下界对照**——网络在该预算下尚未收敛是预期之中、而非需要“发现”的现象；列出它只是为消融提供一个干净的参照起点，而非把它当作被刻意压低以衬托改进的“弱基线”。

表 5.2 AlexNet 组件消融：逐项加入设计要素对测试性能的边际贡献（Fashion-MNIST 测试集）

| 配置                     | 测试准确率  | 宏平均 F1 | 衬衫类 F1 | 较上一行  |
|------------------------|--------|--------|--------|-------|
| 最小配置（15 轮，LRN，欠拟合下界对照） | 0.9155 | 0.9153 | 0.77   | —     |
| + 充分训练（40 轮，余弦退火）      | 0.9314 | 0.9311 | 0.79   | +1.59 |
| + BatchNorm 替代 LRN     | 0.9432 | 0.9429 | 0.83   | +1.18 |
| + 数据增强（即主模型）           | 0.9438 | 0.9437 | 0.83   | +0.06 |




图 5.2 组件消融：充分训练、BatchNorm、数据增强对测试准确率的逐项贡献

消融结果给出了清晰的贡献排序：**BatchNorm 是单步贡献最大的要素**（+1.18 个百分点），它通过稳定各层输入分布显著改善了对视觉相似上装的特征表达，使最难的“**衬衫**”类 F1 由 **0.79 提升至 0.83**；其次是 **充分训练**（+1.59，但这只是把欠拟合补足到正常水平，属基本功而非创新）。数据增强在 40 轮下的边际贡献虽小（+0.06），但其意义在于**方向性的反转**：第 4.6 节中它在 15 轮预算下还是负收益（0.9183→0.9106），充分训练后转为正收益——这一“增强 × 训练时长”的交互，正是不能脱离训练预算孤立评判某个技巧好坏的实证。综合来看，本任务的性能瓶颈在于**特征表达能力**（BN 收益最大），而非损失函数或样本加权（见下节对 Focal Loss 的否认）。

5.3 对照与可解释性分析：为什么是 BatchNorm 而非 Focal Loss

作为对照，我们也验证了一个**被否认**的改进猜想：既然误差集中于上装，是否可用聚焦难分样本的 **Focal Loss** 解决？结果（表 5.3）显示其**不升反降**——这说明困难并非源于样本难易不平衡（Fashion-MNIST 各类样本完全均衡），而是源于特征本身。

表 5.3 被否证的对照：Focal Loss 与交叉熵（去 LRN，15 轮）

| 损失函数       | 测试准确率         | 宏平均 F1        | 衬衫类 F1      | 外套类 F1      |
|------------|---------------|---------------|-------------|-------------|
| 交叉熵 (CE)   | <b>0.9247</b> | <b>0.9245</b> | <b>0.77</b> | <b>0.88</b> |
| Focal Loss | 0.9167        | 0.9163        | 0.75        | 0.86        |

为佐证“瓶颈在特征”这一判断,用 **Grad-CAM** 可视化 AlexNet 的判别依据(图 5.3):模型注意力主要落在服饰主体轮廓,对区分上装所需的细粒度局部缺乏聚焦。这恰好解释了为何**增强特征表达的 BatchNorm 有效、而仅调整样本权重的 Focal Loss 无效**——两条对照路径与可解释性证据相互印证,构成完整的因果闭环。




图 5.3 Grad-CAM 可视化：AlexNet 分类时关注的图像区域（上 = 原图，下 = 热力图叠加）

## 5.4 本章小结

本章通过“诊断—改进—验证”闭环在两个项目上均取得实质成果：项目一用有序回归将严重误判由 7 降至 4，是一处真正改变建模范式的创新；项目二则对 **94.38%** 的主模型做受控消融，定量拆解出各设计要素的贡献（BatchNorm 单步贡献最大、+1.18 个百分点，衬衫类 F1 提升至 0.83），并借助 Focal Loss 的否证对照与 Grad-CAM 可解释性，论证了“性能瓶颈在于特征表达”的因果结论。相比“仅报告精度”的常规做法，这种**用消融与可解释性厘清“性能从何而来”**的实证方法论，是本报告最具价值的创新点。

## 6 实验复现说明

为保证实验结果可复现，本节说明代码结构、运行步骤与关键设置。

### 6.1 代码文件说明

项目源代码按任务组织，各文件职责如表 6.1 所示。

表 6.1 源代码文件说明

| 文件                                           | 功能                          |
|----------------------------------------------|-----------------------------|
| task1_ml_wine/wine_quality.py                | 任务一完整流程：下载/EDA/预处理/四模型训练/评估 |
| task2_alexnet_fmnet/alexnet.py               | 逐层手写的 AlexNet 网络定义          |
| task2_alexnet_fmnet/simplecnn.py             | 轻量基线网络 SimpleCNN            |
| task2_alexnet_fmnet/data.py                  | Fashion-MNIST 加载、变换与三划分     |
| task2_alexnet_fmnet/train.py                 | AlexNet 训练，保存最优 checkpoint  |
| task2_alexnet_fmnet/evaluate.py              | 测试集评估与可视化                   |
| task2_alexnet_fmnet/experiments.py           | 对照实验统一运行器                   |
| task2_alexnet_fmnet/aggregate_experiments.py | 对照实验结果聚合与绘图                 |
| task2_alexnet_fmnet/gradcam.py               | Grad-CAM 可解释性可视化            |
| common/zh_font.py                            | matplotlib 中文字体设置           |
| report/generate_report.py                    | 生成 Word 版报告                 |

## 6.2 运行步骤与关键设置

按以下顺序运行即可复现全部结果（解释器为 conda 环境 pytorch312）：

- (1) 任务一：python task1\_ml\_wine/wine\_quality.py;
- (2) 任务二训练（主模型）：python task2\_alexnet\_fmnet/experiments.py --model alexnet --bn --augment --cosine --epochs 40 --seed 0 --tag main --save-ckpt outputs/alexnet\_best.pt --save-history outputs/history.json;
- (3) 任务二评估：python task2\_alexnet\_fmnet/evaluate.py（加载上一步保存的主模型权重）；
- (4) 对照/消融实验：分别运行 experiments.py（不同 -model/-seed/-no-lrn/-bn/-augment/-epochs 组合）后，执行 python aggregate\_experiments.py 汇总。

**关键设置：**随机种子固定（任务一 train\_test\_split 与各模型 random\_state=42；任务二 PyTorch 种子 0~2）；任务一采用 80/20 分层划分与 5 折交叉验证；任务二主模型使用 SGD（动量 0.9、权重衰减  $5 \times 10^{-4}$ ）、初始学习率 0.01、余弦退火、批大小 128、训练 40 轮，卷积层接 BatchNorm 并对训练集施加数据增强（对照实验则按需关闭相应组件、并采用 15 轮短预算）。软硬件环境见表 2.1，全部图表与指标自动输出到各任务的 outputs/ 目录。

## 7 结论与实验总结

### 7.1 结论

本实训完整实现了两类典型的机器学习任务并得出如下结论：

- (1) 在结构化数据的红酒质量分类中，集成学习方法（随机森林）显著优于单一模型与线性模型，测试集宏平均 F1 达 0.734，是四种算法中的最佳选择；这印证了集成学习在中小规模结构化数据上的普遍优势。
- (2) 在图像分类任务中，逐层手写实现的 AlexNet 能够有效学习服饰图像的层次化特征，经充分训练后测试准确率达 94.38%，充分验证了深度卷积网络在视觉任务上的强大能力以及本次复现的正确性。

## 7.2 实验总结

通过本次实训，我们完整走通了“数据加载—查看—预处理—建模—评估—结论”的机器学习全流程，并获得如下收获：其一，深入理解了传统机器学习与深度学习在数据形态、建模思路与适用场景上的差异；其二，掌握了标准化、分层划分、类别加权等预处理手段及其对结果的影响，体会到“数据决定模型上限”的重要性；其三，熟悉了网格搜索与交叉验证在超参数调优中的作用；其四，通过亲手逐层实现 AlexNet，透彻理解了卷积、池化、ReLU、LRN、Dropout 等核心组件的原理与协同机制。在工程实践中，我们还解决了诸如绘图中文字体缺失数字字形、scikit-learn 新版本参数变更等实际问题，锻炼了独立排查与解决问题的能力。

## 7.3 改进方案

针对两个项目，后续可从以下方向进一步改进：

- **项目一**：尝试 XGBoost、LightGBM 等更强的梯度提升模型；采用 SMOTE(Chawla 等, 2002) 等过采样方法更充分地处理类别不平衡；引入特征工程（如特征交互、分箱）与特征选择以提升判别力；也可尝试将质量评分作为回归任务建模后再分级。
- **项目二**：引入数据增强（随机裁剪、翻转、旋转）以抑制过拟合并提升泛化；用批归一化（BatchNorm）(Ioffe 和 Szegedy, 2015) 替代 LRN 以加速收敛、稳定训练；适当增加训练轮数并采用余弦退火等更精细的学习率策略；亦可对比 VGG(Simonyan 和 Zisserman, 2015)、ResNet(He 等, 2016) 等更先进的网络结构，分析深度对精度的影响。
- **通用**：建立更系统的实验管理与超参数搜索流程，对关键结果进行多次重复实验以评估稳定性，并引入更全面的可视化与误差分析手段。

## 参考文献

周志华. 机器学习 [M]. 北京: 清华大学出版社, 2016: 23-200.

Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.

Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321-357.

Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.

- Cortez P, Cerdeira A, Almeida F, et al. Modeling wine preferences by data mining from physicochemical properties[J]. *Decision Support Systems*, 2009, 47(4): 547-553.
- He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//*IEEE Conference on Computer Vision and Pattern Recognition*. 2016: 770-778.
- Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C]//*International Conference on Machine Learning*. 2015: 448-456.
- Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//*Advances in Neural Information Processing Systems*. 2012: 1097-1105.
- Paszke A, Gross S, Massa F, et al. PyTorch: an imperative style, high-performance deep learning library[C]//*Advances in Neural Information Processing Systems*. 2019: 8024-8035.
- Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: machine learning in Python[J]. *Journal of Machine Learning Research*, 2011, 12: 2825-2830.
- Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//*International Conference on Learning Representations*. 2015.
- Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. *Journal of Machine Learning Research*, 2014, 15(1): 1929-1958.
- Xiao H, Rasul K, Vollgraf R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms[J]. *arXiv preprint arXiv:1708.07747*, 2017.